
@inproceedingsredmon2016yolo, Author = Joseph Redmon and Santosh Divvala and Ross Girshick and Ali Farhadi, Booktitle = Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Month = 6, Pages = 779–788, Title = You Only Look Once: Unified, Real-Time Object Detection, Url = <https://ieeexplore.ieee.org/document/7780>, Year = 2016

@articleranftl2020midas, Author = René Ranftl and Katrin Lasinger and David Hafner and Konrad Lang and Konrad Schindler, Journal = IEEE Transactions on Pattern Analysis and Machine Intelligence, Month = 3, Number = 3, Pages = 1623–1637, Title = Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-shot Cross-dataset Transfer, Volume = 44, Url = <https://ieeexplore.ieee.org/document/9226433>, Year = 2020

@inproceedingszhang2022bytetrack, Author = Yifu Zhang and Peize Sun and Yi Jiang and Dongdong Yu and Fucheng Weng and Zehuan Yuan and Ping Luo and Wenyu Liu and Xinggang Wang, Booktitle = Proceedings of the European Conference on Computer Vision (ECCV), Month = 10, Pages = 1–21, Title = ByteTrack: Multi-Object Tracking by Associating Every Detection Box, Url = https://link.springer.com/chapter/10.1007/978-3-031-20047-2_1, Year = 2022

@articlebai2017smart, Author = Jian Bai and Shiguo Lian and Zhaoxiang Liu and Kai Wang and Dijun Liu, Journal = IEEE Transactions on Consumer Electronics, Month = 8, Number = 3, Pages = 259–266, Title = Smart Guiding Glasses for Visually Impaired People in Indoor Environment, Volume = 63, Url = <https://ieeexplore.ieee.org/document/8016484>, Year = 2017

@articlewang2021realtime, Author = He Wang and Yiling Lin and Xiaohui Wang, Journal = Journal of Real-Time Image Processing, Month = 4, Number = 4, Pages = 1245–1258, Title = Real-time Object

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA VẬT LÝ



TÊN SINH VIÊN THỰC HIỆN

TÊN CỦA KHÓA LUẬN TỐT NGHIỆP/TIỂU LUẬN

Khóa luận tốt nghiệp đại học hệ chính quy

Tên ngành đào tạo

(Tên chương trình đào tạo)

Hà Nội - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA VẬT LÝ



TÊN SINH VIÊN THỰC HIỆN

TÊN CỦA KHÓA LUẬN TỐT NGHIỆP/TIỂU LUẬN

Khóa luận tốt nghiệp đại học hệ chính quy

Tên ngành đào tạo

(Tên chương trình đào tạo)

Giảng viên hướng dẫn: Tên giảng viên hướng dẫn 1

Tên giảng viên hướng dẫn 2

Hà Nội - 2026

Lời cảm ơn

Trong quá trình thực hiện môn học Đồ án Kỹ thuật Điện tử và Tin học để hoàn thành bài báo cáo này, em đã nhận được rất nhiều sự quan tâm, hướng dẫn và hỗ trợ quý báu từ thầy Vi Anh Quân. Em xin bày tỏ lòng biết ơn chân thành và sâu sắc đến thầy vì sự tận tâm trong giảng dạy, những góp ý chuyên môn quý báu cũng như sự hỗ trợ nhiệt tình trong suốt quá trình học tập và thực hiện đề tài.

Những kiến thức và kinh nghiệm mà thầy truyền đạt không chỉ giúp em hoàn thành tốt bài báo cáo mà còn là nền tảng quan trọng cho quá trình học tập và phát triển trong tương lai. Sự nghiêm túc, nhiệt huyết và tinh thần trách nhiệm của thầy đã trở thành động lực lớn để em nỗ lực hơn trong quá trình nghiên cứu và thực hiện đề tài.

Mặc dù đã cố gắng hoàn thiện đề tài này một cách tốt nhất, do kiến thức và kinh nghiệm thực tiễn còn hạn chế nên khó tránh khỏi những thiếu sót nhất định. Em rất mong nhận được những ý kiến đóng góp và nhận xét từ thầy để có thể tiếp tục hoàn thiện và nâng cao kiến thức của bản thân.

Lời cuối cùng, em xin kính chúc thầy luôn mạnh khỏe, hạnh phúc và đạt nhiều thành công trong sự nghiệp giảng dạy của mình.

Em xin chân thành cảm ơn!

Mục lục

Danh sách hình vẽ

Danh sách bảng

Danh sách tên viết tắt

TVT	Tên Viết Tắt
ĐTD	Đặt (nó) Tại Đây

MỞ ĐẦU

Trong bối cảnh công nghệ trí tuệ nhân tạo (AI) và thị giác máy tính đang phát triển mạnh mẽ, các ứng dụng hỗ trợ con người trong đời sống ngày càng được quan tâm và nghiên cứu rộng rãi. Đặc biệt, đối với người khiếm thị, việc di chuyển và nhận biết môi trường xung quanh luôn là một thách thức lớn do hạn chế về khả năng quan sát. Những khó khăn trong việc phát hiện vật cản, xác định khoảng cách hay nhận biết nguy hiểm có thể ảnh hưởng trực tiếp đến sự an toàn và khả năng sinh hoạt độc lập của người khiếm thị trong cuộc sống hàng ngày.

Hiện nay, nhiều giải pháp hỗ trợ người khiếm thị đã được nghiên cứu và phát triển, từ các thiết bị cảm biến siêu âm truyền thống cho đến các hệ thống ứng dụng trí tuệ nhân tạo và học sâu (Deep Learning). Trong đó, các phương pháp sử dụng thị giác máy tính kết hợp với nhận diện đối tượng và ước lượng khoảng cách đang cho thấy nhiều tiềm năng nhờ khả năng xử lý thông tin trực quan nhanh chóng, chính xác và có thể hoạt động trong thời gian thực. Tuy nhiên, việc xây dựng các phương pháp có độ chính xác cao, khả năng thích nghi tốt với môi trường thực tế và đáp ứng yêu cầu xử lý thời gian thực vẫn còn là một bài toán cần được nghiên cứu và cải thiện.

Xuất phát từ thực tế đó, nhóm em lựa chọn đề tài “Phương pháp nhận diện vật cản và ước lượng khoảng cách để hỗ trợ người khiếm thị”. Đề tài tập trung nghiên cứu các phương pháp nhận diện vật cản dựa trên mô hình học sâu kết hợp với kỹ thuật ước lượng khoảng cách nhằm hỗ trợ người khiếm thị trong quá trình di chuyển. Thông qua việc phân tích, xây dựng và đánh giá các mô hình phù hợp, đề tài hướng tới việc nâng cao khả năng nhận biết môi trường xung quanh, hỗ trợ cảnh báo vật cản và tăng độ an toàn cho người khiếm thị.

Trong báo cáo này, nhóm em trình bày quá trình nghiên cứu lý thuyết, xây dựng

phương pháp, triển khai mô hình và đánh giá kết quả thực nghiệm cho bài toán nhận diện vật cản và ước lượng khoảng cách nhằm hỗ trợ người khiếm thị. Báo cáo tập trung phân tích cách thức hoạt động của mô hình, khả năng nhận diện vật cản cũng như hiệu quả ước lượng khoảng cách trong các điều kiện thực tế khác nhau. Qua đó, đề tài hướng tới việc đề xuất một phương pháp hỗ trợ người khiếm thị trong quá trình di chuyển, góp phần nâng cao tính an toàn và khả năng ứng dụng của các giải pháp hỗ trợ thông minh trong thực tế.

Chương 1 TỔNG QUAN ĐỀ TÀI

1.1 Giới thiệu bài toán

Trong kỷ nguyên của trí tuệ nhân tạo và các hệ thống tự hành, bài toán nhận diện vật cản và ước lượng khoảng cách đã trở thành một trong những hướng nghiên cứu trọng tâm và tiên phong của lĩnh vực Thị giác máy tính (Computer Vision). Ý nghĩa của bài toán này không chỉ dừng lại ở việc tối ưu hóa công nghệ, mà còn mang giá trị nhân văn sâu sắc khi được ứng dụng để xây dựng các hệ thống điều hướng thông minh, hỗ trợ người khiếm thị tái hòa nhập cộng đồng. Đối với người khiếm thị, việc di chuyển trong môi trường thực tế là một thách thức lớn khi xung quanh luôn tồn tại các mối nguy cơ chuyển động liên tục và bất ngờ như người đi bộ, xe máy, ô tô, hoặc các chướng ngại vật tĩnh như cột điện, biển báo, bàn ghế. Một hệ thống trợ thính hoặc trợ thị thông minh không chỉ cần đóng vai trò như một đôi mắt thứ hai để nhận biết môi trường, mà còn phải là một bộ não có khả năng phân tích không gian trong thời gian thực, từ đó đưa ra những chỉ dẫn an toàn và kịp thời cho người dùng.

Để giải quyết trọn vẹn bài toán hỗ trợ điều hướng, hệ thống không thể dựa vào một kỹ thuật đơn lẻ mà phải phối hợp nhịp nhàng một chuỗi các tác vụ phức tạp theo trình tự tuyến tính. Đầu tiên là tác vụ nhận diện đối tượng (Object Detection) nhằm phân tích các khung hình thu nhận từ camera để xác định chính xác danh tính và vị trí của các vật cản xuất hiện trong tầm nhìn. Tiếp theo, tác vụ theo dõi đối tượng (Object Tracking) được thực hiện để duy trì thông tin định danh của từng vật thể xuyên suốt các khung hình liên tiếp, giúp hệ thống hiểu được quỹ đạo và hướng di chuyển của vật cản, đồng thời phân biệt giữa chướng ngại vật tĩnh và động. Cuối cùng, tác vụ ước lượng độ sâu (Depth Estimation) tiến hành đo lường khoảng cách tương đối từ camera đến vật cản, cung cấp dữ liệu số học nền tảng để đánh giá mức độ rủi ro va chạm.

Mặc dù lý thuyết về các mô hình độc lập đã đạt được nhiều bước tiến, việc tích hợp chúng vào một hệ thống hỗ trợ người khiếm thị trong môi trường thực tế vẫn đối mặt với những rào cản kỹ thuật lớn. Sự biến động của môi trường như điều kiện ánh sáng thay đổi thất thường, mật độ giao thông đông đúc, và hiện tượng các vật cản che khuất lẫn nhau dễ làm giảm độ chính xác của mô hình nhận diện. Bên cạnh đó, hệ thống phục vụ người đi lại luôn yêu cầu tốc độ phản hồi cực cao dưới áp lực xử lý thời gian thực, bởi bất kỳ sự trễ nào trong quá trình tính toán đều có thể dẫn đến nguy cơ va chạm thực tế. Ngoài ra, việc lồng ghép nhiều mô hình học sâu (Deep Learning) vào cùng một hệ thống sẽ gây áp lực lớn lên tài nguyên phần cứng, đòi hỏi phải giải quyết triệt để bài toán tối ưu hóa tốc độ xử lý và đồng bộ hóa dữ liệu giữa các luồng thuật toán.

Để vượt qua các thách thức trên, đề tài này đề xuất một giải pháp toàn diện mang tính đột phá dựa trên việc kết hợp các công nghệ tiên tiến nhất hiện nay. Hệ thống sử dụng mô hình YOLO26 làm kiến trúc cốt lõi cho tác vụ nhận diện vật cản nhờ tốc độ xử lý vượt trội và khả năng nhận diện đa lớp vật thể chính xác. Song song với đó, thuật toán ByteTrack được tích hợp để theo dõi đối tượng xuyên khung hình, duy trì quỹ đạo chuyển động ổn định ngay cả khi vật cản bị che khuất tạm thời. Đối với việc tính toán khoảng cách, mô hình MiDaS được ứng dụng để ước lượng độ sâu từ ảnh đơn, cho phép tối ưu chi phí phần cứng mà không cần đến các hệ thống camera kép hay cảm biến đắt đỏ. Cuối cùng, các luồng dữ liệu này được tổng hợp thông qua một thuật toán phân tích mức độ nguy hiểm để phát ra cảnh báo bằng giọng nói tiếng Việt trực quan, hướng tới một giải pháp công nghệ có độ chính xác cao và hoạt động mượt mà trong thời gian thực.

1.2 Các phương pháp nghiên cứu trước đây

Trong lĩnh vực nhận diện vật cản và hỗ trợ điều hướng thông minh, việc áp dụng trí tuệ nhân tạo, đặc biệt là các mô hình học sâu (Deep Learning), đã tạo nên những bước đột phá mạnh mẽ. Các nghiên cứu trước đây chủ yếu tập trung vào bài toán phát hiện đối

tượng (Object Detection) nhằm xác định đồng thời vị trí và nhãn phân loại của các vật thể trong môi trường. Dựa trên cấu trúc kiến trúc mạng, các phương pháp này được chia thành hai nhóm tiếp cận chính bao gồm bộ dò hai giai đoạn (Two-stage detector) và bộ dò một giai đoạn (One-stage detector). Việc phân tích và đánh giá chi tiết các phương pháp điển hình này là cơ sở lý thuyết quan trọng để định hình giải pháp tối ưu cho hệ thống hỗ trợ người khiếm thị.

1.2.1 Phương pháp Faster R-CNN


Faster R-CNN là mô hình đại diện tiêu biểu và thành công nhất trong nhóm kiến trúc bộ dò hai giai đoạn. Mô hình này ra đời nhằm khắc phục nhược điểm về tốc độ của các phiên bản tiền nhiệm bằng cách loại bỏ thuật toán trích xuất vùng đề xuất truyền thống mang tính thủ công và thay thế bằng một mạng thần kinh tích chập đồng bộ. Quy trình hoạt động của Faster R-CNN được chia làm hai giai đoạn rõ rệt. Trong giai đoạn đầu tiên, hình ảnh đầu vào được xử lý qua một mạng nền tảng để trích xuất ra các bản đồ đặc trưng, sau đó một mạng đề xuất vùng chuyên biệt có tên gọi là Region Proposal Network sẽ tiến hành quét qua bản đồ này để dự đoán xác suất chứa đối tượng và đưa ra các khung hình ứng viên sơ bộ. Sang giai đoạn thứ hai, các vùng đề xuất được chuẩn hóa về một kích thước cố định thông qua lớp RoI Pooling rồi chuyển đến các lớp kết nối đầy đủ để thực hiện song song hai nhiệm vụ là phân loại chính xác nhãn của đối tượng và tính chỉnh tối ưu tọa độ khung bao cuối cùng.

Nhờ cơ chế tách biệt hai giai đoạn mang tính tuần tự này, Faster R-CNN sở hữu ưu điểm vượt trội về độ chính xác khi nhận diện. Mô hình đặc biệt xuất sắc trong việc phát hiện các vật thể có kích thước nhỏ, cấu trúc phức tạp hoặc các đối tượng bị che khuất một phần trong không gian. Tuy nhiên, nhược điểm lớn nhất của Faster R-CNN lại nằm ở tốc độ suy luận do việc phải xử lý hàng ngàn vùng đề xuất tiêu tốn lượng tài nguyên tính toán cực kỳ lớn. Chính sự hạn chế về mặt tốc độ này khiến mô hình không đạt được

tính khả thi khi triển khai trên các thiết bị nhúng cầm tay hoặc các hệ thống yêu cầu phản hồi thời gian thực tức thời như thiết bị hỗ trợ người khiếm thị di chuyển.

1.2.2 Phương pháp SSD


Mô hình SSD (Single Shot MultiBox Detector) được giới thiệu nhằm mục tiêu tối ưu hóa tốc độ xử lý của kiến trúc một giai đoạn nhưng vẫn cố gắng duy trì độ chính xác tiệm cận với các bộ dò hai giai đoạn phức tạp. Cấu trúc và cơ chế hoạt động cốt lõi của SSD được xây dựng dựa trên sự kết hợp của ba thành phần kỹ thuật nền tảng bao gồm mạng nền tảng cơ sở, hệ thống bản đồ đặc trưng đa tỷ lệ và cơ chế khung neo mặc định.



Hình 1.1: Kiến trúc của phương pháp SSD.

Mạng cơ sở của SSD thường sử dụng kiến trúc VGG-16 hoặc MobileNet đã được loại bỏ các tầng kết nối đầy đủ (Fully Connected Layers) nhằm trích xuất các đặc trưng thô từ hình ảnh đầu vào với chi phí tính toán thấp. Điểm cải tiến lớn nhất của SSD so với các mô hình cùng thời kỳ nằm ở việc bổ sung một chuỗi các tầng tích chập phụ với kích thước giảm dần một cách lũy tiến ngay sau mạng nền tảng, tạo ra một hệ thống các bản đồ đặc trưng đa tỷ lệ (Multi-scale Feature Maps). Quy trình này cho phép mô hình thực hiện dự đoán độc lập trên nhiều tầng mạng khác nhau. Cụ thể, các tầng bản đồ kích thước lớn ở phía nông có độ phân giải không gian cao sẽ chịu trách nhiệm phát hiện các vật thể kích thước nhỏ, trong khi các tầng bản đồ kích thước nhỏ ở phía sâu chứa nhiều hàm

lượng thông tin ngữ nghĩa cao cấp sẽ chịu trách nhiệm cấu trúc và phát hiện các vật thể có kích thước lớn hơn.



Hình 1.2: Sơ đồ kiến trúc và cơ chế hoạt động của phương pháp SSD.

Tại mỗi ô lưới trên từng bản đồ đặc trưng đa tỷ lệ này, SSD phân bố một tập hợp các khung neo mặc định (Default Boxes) với nhiều tỷ lệ khía cạnh và kích thước hình học khác nhau. Trong quá trình suy luận, mô hình sẽ tính toán trực tiếp độ lệch tọa độ của khung bao thực tế so với các khung neo mặc định này, đồng thời dự đoán điểm số tin cậy cho từng lớp đối tượng cụ thể. Cuối cùng, hệ thống áp dụng thuật toán triệt tiêu cực đại không giao nhau (Non-Maximum Suppression) để lọc sạch các khung bao chồng chéo và giữ lại kết quả tối ưu nhất.

1. Vấn đề của phương pháp SSD

Mặc dù SSD (Single Shot MultiBox Detector) là một cột mốc công nghệ quan trọng trong sự phát triển của lĩnh vực thị giác máy tính, việc không lựa chọn mô hình này làm kiến trúc nhận diện cho hệ thống hỗ trợ người khiếm thị xuất phát từ hai nguyên nhân kỹ thuật cốt lõi sau đây.


Nguyên nhân đầu tiên nằm ở sự hạn chế cố hữu về mặt kiến trúc, dẫn đến hiệu năng nhận diện kém đối với các chướng ngại vật nhỏ hoặc nằm ở khoảng cách xa. Đối với

người khiếm thị, việc phát hiện sớm các nguy cơ từ xa như cột điện, biển báo, hoặc các vật thể nhỏ dưới lòng đường như viên gạch, hố sụt là yếu tố quyết định đến sự an toàn vật lý trong quá trình di chuyển. Tuy nhiên, cấu trúc của SSD lại thực hiện việc trích xuất đặc trưng và dự đoán theo một chiều thẳng đứng từ nông đến sâu, hoàn toàn thiếu vắng các cơ chế hợp nhất đặc trưng hiện đại như mạng kim tự tháp đặc trưng (Feature Pyramid Network) hay mạng tổng hợp đường dẫn (Path Aggregation Network). Do SSD tiến hành dự đoán các vật thể nhỏ hoàn toàn độc lập dựa trên các tầng mạng nông ban đầu, nơi hàm lượng thông tin ngữ nghĩa còn rất nghèo nàn và mạng chưa hiểu rõ cấu trúc vật thể nên bài toán rất dễ bỏ sót mục tiêu hoặc đưa ra các cảnh báo sai lệch. Ngược lại, các dòng mạng thế hệ mới hiện nay sử dụng cơ chế kết nối ngược linh hoạt, cho phép thông tin ngữ nghĩa cấp cao bổ sung liên tục cho thông tin không gian ở tầng thấp, giải quyết triệt để bài toán nhận diện vật thể đa quy mô mà SSD gặp phải.

Nguyên nhân thứ hai xuất phát từ áp lực tối ưu hóa hiệu năng và tính bất tương thích của SSD khi đặt trong một hệ sinh thái đa tác vụ thời gian thực. Hệ thống đề xuất của đề tài không thuần túy là một bộ dò ảnh đơn lẻ, mà là một phức hợp công nghệ hoạt động đồng thời bao gồm nhận diện vật cản, theo dõi quỹ đạo bằng ByteTrack và ước lượng độ sâu bằng mô hình MiDaS. Bản thân MiDaS là một cấu trúc học sâu từ ảnh đơn tương đối nặng và chiếm dụng nhiều tài nguyên đồ họa; do đó, nếu lựa chọn SSD, hệ thống sẽ buộc phải nâng cấp mạng nền tảng lên cấu hình rất lớn để bù đắp lỗ hổng về độ chính xác, vô tình tạo ra hiện tượng thắt nút cổ chai về mặt hiệu năng và làm sụt giảm nghiêm trọng tốc độ khung hình (FPS) trên các thiết bị nhúng. Bên cạnh đó, SSD thường xuyên gặp hiện tượng rung lắc khung bao (bounding box jittering) khi đối tượng chuyển động nhanh. Nhược điểm này trực tiếp phá vỡ tính ổn định của thuật toán ByteTrack — vốn là liên kết phụ thuộc chặt chẽ vào độ tin cậy và tọa độ chuẩn xác của khung bao để duy trì định danh vật thể xuyên suốt video. Vì vậy, việc loại bỏ SSD để hướng tới một kiến trúc đồng bộ, mượt mà và tối ưu phần cứng là lựa chọn tất yếu để đảm bảo tính an toàn cao nhất cho người dùng.

1.2.3 Phương pháp RetinaNet

RetinaNet là một mô hình một giai đoạn mang tính đột phá được đề xuất nhằm giải quyết triệt để bài toán mất cân bằng nghiêm trọng giữa lớp nền và lớp đối tượng, một điểm yếu cốt lõi khiến các bộ dò một giai đoạn trước đó có độ chính xác thấp hơn bộ dò hai giai đoạn. Kiến trúc của RetinaNet là sự kết hợp tinh tế giữa mạng nền tảng ResNet, mạng kim tự tháp đặc trưng (Feature Pyramid Network) để trích xuất đặc trưng đa quy mô đa tầng, và hai mạng nhánh phụ chuyên biệt chịu trách nhiệm phân loại đối tượng và hồi quy khung bao. Điểm đổi mới quan trọng nhất làm nên sự thành công của RetinaNet là việc giới thiệu một hàm mất mát mới mang tên Focal Loss. Hàm mất mát này tự động hạ thấp trọng số đóng góp của các mẫu dễ nhận diện (chủ yếu là vùng nền trống) và tập trung sự chú ý của mô hình vào các mẫu khó nhận diện (vật cản thực tế), giúp mạng học được các đặc trưng quan trọng một cách hiệu quả hơn.



Hình 1.3: Kiến trúc phương pháp RetinaNet.

Về mặt ưu điểm, RetinaNet đạt được sự cân bằng lý tưởng khi sở hữu độ chính xác cao tiệm cận với các mô hình hai giai đoạn phức tạp như Faster R-CNN, nhưng vẫn duy trì được tốc độ xử lý nhanh chóng của một bộ dò một giai đoạn nhờ cấu trúc không cần vùng đề xuất. Điều này giúp mô hình nhận diện tốt các chương ngại vật đa dạng trên đường phố ngay cả trong điều kiện mật độ giao thông đông đúc. Tuy nhiên, nhược điểm của RetinaNet là cấu trúc mạng kim tự tháp đặc trưng đi kèm với cơ chế Focal Loss vẫn

đòi hỏi một lượng tài nguyên tính toán nhất định ở giai đoạn huấn luyện và có thể gặp hiện tượng giảm tốc độ nhẹ trên các vi điều khiển công suất thấp nếu không được tối ưu hóa hoặc nén mô hình một cách hợp lý.

Tổng kết lại, việc phân tích các đặc điểm kiến trúc của Faster R-CNN, SSD và RetinaNet mang lại cái nhìn toàn diện về sự đánh đổi giữa tốc độ và độ chính xác trong bài toán thị giác máy tính. Đây chính là nền tảng lý thuyết vững chắc giúp định hình và xây dựng một phương pháp nhận diện tối ưu, có khả năng xử lý mượt mà trong thời gian thực nhưng vẫn bảo đảm độ chính xác tối đa để bảo vệ an toàn cho người khiếm thị.

1.3 Phương pháp đề xuất

Trong đề tài này, phương pháp đề xuất tập trung vào việc xây dựng phương pháp hỗ trợ điều hướng thông minh dành cho người khiếm thị thông qua việc kết hợp nhiều mô hình trí tuệ nhân tạo trong cùng một pipeline. Hệ thống sử dụng camera để thu nhận dữ liệu hình ảnh từ môi trường xung quanh, sau đó thực hiện nhận diện vật cản, theo dõi đối tượng, ước lượng khoảng cách và cảnh báo nguy hiểm bằng giọng nói.

Kiến trúc tổng thể của phương pháp được xây dựng theo hướng xử lý song song nhằm tăng tốc độ xử lý và đảm bảo khả năng hoạt động thời gian thực. Dữ liệu đầu vào có thể là hình ảnh, video hoặc luồng camera trực tiếp. Sau khi dữ liệu được đưa vào hệ thống, quá trình xử lý sẽ được chia thành nhiều giai đoạn khác nhau.

Đầu tiên, mô hình YOLO26 được sử dụng để thực hiện bài toán nhận diện vật cản. Mô hình có nhiệm vụ phát hiện các đối tượng xuất hiện trong khung hình như người đi bộ, xe máy, ô tô hoặc các chướng ngại vật khác. YOLO26 được lựa chọn do có khả năng xử lý nhanh và phù hợp với các ứng dụng thời gian thực. Ngoài ra, mô hình được fine-tune trên tập dữ liệu phù hợp nhằm nâng cao độ chính xác trong môi trường thực tế.

Song song với quá trình nhận diện đối tượng, hệ thống sử dụng mô hình MiDaS để thực hiện bài toán Monocular Depth Estimation. Mô hình này cho phép ước lượng độ

sâu và khoảng cách của vật thể chỉ từ một camera đơn mà không cần sử dụng camera stereo hoặc cảm biến chuyên dụng. Kết quả của MiDaS là bản đồ độ sâu (Depth Map), thể hiện mức độ gần hoặc xa của các vật thể trong không gian.

Sau khi phát hiện đối tượng, hệ thống sử dụng thuật toán ByteTrack để thực hiện theo dõi đa đối tượng (Multi-Object Tracking). ByteTrack có nhiệm vụ gán ID cho từng đối tượng và duy trì việc theo dõi xuyên suốt nhiều khung hình liên tiếp. Điều này giúp hệ thống xác định được hướng di chuyển cũng như trạng thái thay đổi của vật cản theo thời gian thực.

Kết quả từ YOLO26, MiDaS và ByteTrack được đưa vào Fusion Pipeline để tổng hợp thông tin. Tại đây, hệ thống kết hợp thông tin về loại đối tượng, vị trí, hướng di chuyển và khoảng cách nhằm phân tích mức độ nguy hiểm của từng vật cản đối với người dùng.

Dựa trên kết quả phân tích, hệ thống Danger Analyzer sẽ xác định mức độ cảnh báo phù hợp. Nếu phát hiện vật cản nguy hiểm hoặc đối tượng đang di chuyển đến gần người dùng, hệ thống sẽ sinh nội dung cảnh báo tương ứng.

Cuối cùng, hệ thống sử dụng Text-to-Speech (TTS) tiếng Việt thông qua gTTS hoặc eSpeak để chuyển nội dung cảnh báo thành giọng nói. Cảnh báo âm thanh được phát theo thời gian thực nhằm hỗ trợ người khiếm thị nhận biết môi trường xung quanh và nâng cao độ an toàn trong quá trình di chuyển.


Ngoài ra, hệ thống còn được triển khai với FastAPI và WebSocket ở phía backend nhằm hỗ trợ xử lý ảnh/video và truyền dữ liệu thời gian thực. Giao diện frontend được xây dựng bằng React và Vite, giúp hiển thị trực quan kết quả nhận diện và hỗ trợ quản lý toàn bộ hệ thống.

Chương 2 CƠ SỞ LÝ THUYẾT

2.1 Mô hình phát hiện đối tượng YOLO

YOLO là 1 từ viết tắt cho ‘You only look once’ (Bạn chỉ nhìn một lần) là một thuật toán phát hiện đối tượng chia hình ảnh thành một hệ thống lưới. Mỗi ô trong lưới chịu trách nhiệm phát hiện các đối tượng trong chính nó. YOLO là một trong những thuật toán phát hiện đối tượng nổi tiếng nhất do tốc độ và độ chính xác của nó.

YOLO là một mô hình mạng CNN cho việc phát hiện, nhận dạng, phân loại đối tượng. YOLO được tạo ra từ việc kết hợp giữa các convolutional layers và connected layers. Trong đó các convolutional layers sẽ trích xuất ra các feature của ảnh, còn fullconnected layers sẽ dự đoán ra xác suất đó và tọa độ của đối tượng.



Hình 2.1: Mô hình mạng CNN được sử dụng trong YOLO

Hình ảnh đầu vào sẽ được chia thành một lưới kích thước $S \times S$, trong đó mỗi ô lưới chịu trách nhiệm phát hiện các đối tượng có tâm nằm trong ô đó. Đối với mỗi ô, mô hình sẽ dự đoán một số lượng bounding box cùng với thông tin về vị trí và xác suất lớp.


Với mỗi bounding box, mô hình dự đoán 5 tham số bao gồm $(x, y, w, h, confidence)$. Trong đó, (x, y) là tọa độ tâm của bounding box tương đối so với ô lưới, còn (w, h) là

chiều rộng và chiều cao được chuẩn hóa theo kích thước toàn ảnh. Giá trị *confidence* thể hiện mức độ tin cậy của bounding box, được tính dựa trên xác suất tồn tại đối tượng và độ chồng lấp giữa bounding box dự đoán và ground truth.

Ngoài ra, mỗi ô lưới còn dự đoán xác suất thuộc về các lớp đối tượng dưới dạng $Pr(Class_i | Object)$. Xác suất cuối cùng của một lớp được tính bằng cách kết hợp giữa xác suất lớp và *confidence* của bounding box.

2.1.1 Mô hình YOLO26

YOLO26 (hay YOLOv26) là thế hệ mới nhất thuộc họ mô hình phát hiện đối tượng You Only Look Once (YOLO) do Ultralytics phát triển, được giới thiệu vào khoảng cuối năm 2025. Khác với các phiên bản trước chủ yếu tập trung vào việc gia tăng độ chính xác thông qua việc mở rộng kích thước mô hình, YOLO26 được thiết kế lại nhằm tối ưu hóa cho việc triển khai trên các thiết bị biên (edge devices), hệ thống nhúng và môi trường có tài nguyên hạn chế.




Hình 2.2: Kiến trúc tổng quan YOLO26

1. Kiến trúc NMS-Free

Các phiên bản YOLO trước đây (như YOLOv8, YOLOv9) yêu cầu bước hậu xử lý Non-Maximum Suppression (NMS) để loại bỏ các bounding box trùng lặp. Tuy nhiên, YOLO26 được thiết kế theo hướng end-to-end hoàn chỉnh, cho phép mô hình trực tiếp xuất ra các dự đoán cuối cùng mà không cần áp dụng NMS.

Việc loại bỏ bước NMS giúp giảm độ trễ của toàn hệ thống và đơn giản hóa pipeline suy luận, đặc biệt phù hợp với các ứng dụng thời gian thực.




Hình 2.3: Kiến trúc NMS-Free

2. Loại bỏ Distribution Focal Loss

Trong các phiên bản trước, Distribution Focal Loss (DFL) được sử dụng để cải thiện độ chính xác của bounding box. Tuy nhiên, DFL gây khó khăn trong việc chuyển đổi mô hình sang các định dạng triển khai như TensorRT, ONNX hay CoreML.

YOLO26 loại bỏ hoàn toàn DFL, giúp quá trình export và triển khai mô hình trở nên đơn giản, ổn định và tương thích tốt hơn với phần cứng.




Hình 2.4: Loại bỏ DFL

3. Tối ưu phát hiện vật thể nhỏ

YOLO26 áp dụng cơ chế gán nhãn mới mang tên Small-Target-Aware Label Assignment (STAL), kết hợp với hàm mất mát cải tiến. Cơ chế này giúp mô hình nhạy hơn với các vật thể nhỏ hoặc ở khoảng cách xa.

Nhờ đó, hiệu năng phát hiện các đối tượng nhỏ như biển số xe hoặc chi tiết chữ viết tay được cải thiện đáng kể so với các phiên bản trước.




Hình 2.5: Tối ưu cho vật thể nhỏ

4. Trình tối ưu hóa MuSGD

YOLO26 sử dụng trình tối ưu hóa MuSGD, kết hợp giữa Stochastic Gradient Descent (SGD) và thuật toán Muon. Phương pháp này giúp cải thiện tốc độ hội tụ và đảm bảo sự ổn định trong quá trình huấn luyện.

Việc áp dụng MuSGD cho phép mô hình đạt hiệu năng cao mà vẫn duy trì độ ổn định khi huấn luyện trên các tập dữ liệu lớn.



Hình 2.6: Tối ưu hóa MuSGD

Nhờ đó, YOLO26 có thể được sử dụng như một nền tảng thống nhất cho nhiều ứng dụng khác nhau trong thị giác máy tính.

2.2 Ước lượng chiều sâu từ ảnh đơn với mô hình MiDaS

2.2.1 Bài toán *Monocular Depth Estimation*


Ước lượng chiều sâu từ ảnh đơn (*Monocular Depth Estimation*) là quá trình dự đoán khoảng cách của các vật thể trong một bức ảnh 2D so với góc nhìn của camera, mà không cần sử dụng đến hệ thống camera kép (*Stereo camera*) hay các cảm biến không gian chuyên dụng như LiDAR. Đối với hệ thống hỗ trợ người khiếm thị SmartNav, việc áp dụng bài toán này mang ý nghĩa cốt lõi, cho phép hệ thống phân tích và ước lượng khoảng cách của chướng ngại vật ngay trên các thiết bị di động có cấu hình phần cứng giới hạn.

Thay vì trả về giá trị khoảng cách tuyệt đối tính bằng mét, đầu ra của mô hình thường là một bản đồ thị sai (*Disparity Map*). Trong bản đồ này, giá trị điểm ảnh (pixel) càng lớn biểu thị vật thể càng gần camera, và ngược lại. Khó khăn lớn nhất của bài toán này

nằm ở tính nhập nhằng (ambiguity) của không gian 2D, khi một vật thể nhỏ ở gần có thể tạo ra hình chiếu trên cảm biến tương đương với một vật thể lớn ở xa.

2.2.2 Kiến trúc mô hình MiDaS

Để giải quyết thách thức trên, hệ thống SmartNav ứng dụng mô hình MiDaS (Multiple Depth Estimation Datasets), một mạng nơ-ron được huấn luyện trên nhiều bộ dữ liệu khác nhau để đảm bảo khả năng tổng quát hóa tốt nhất trên mọi môi trường thực tế như trong nhà, ngoài trời và đường phố đô thị.



Hình 2.7: So sánh ảnh RGB gốc và bản đồ độ sâu (Depth Map) được trích xuất từ mô hình MiDaS

Trong dự án này, phiên bản MiDaS loại nhỏ (`MiDaS_small`) được lựa chọn nhằm tối ưu hóa tốc độ xử lý trên CPU và các thiết bị biên (Edge Devices). Quá trình xử lý độ sâu được thực hiện thông qua các bước chính:

- **Tiền xử lý và Nội suy:** Hình ảnh RGB đầu vào được chuẩn hóa bằng hàm biến đổi đặc thù của MiDaS, sau đó được đưa qua mạng nơ-ron để dự đoán bản đồ thị sai. Kết quả đầu ra được nội suy bậc ba (Bicubic Interpolation) để đồng bộ lại với kích thước khung hình gốc của camera.

- **Chuẩn hóa Min-Max (Min-Max Normalization):** Nhằm tạo ra một thang đo đồng nhất cho thuật toán cảnh báo, bản đồ thị sai được chuẩn hóa về dải giá trị từ 0 đến 1. Trong đó, mức 1.0 đại diện cho điểm gần nhất và 0.0 là điểm xa nhất ở đường chân trời.
- **Lọc nhiễu bằng Bách phân vị (Percentile Filtering):** Khi hệ thống nhận diện được một vật cản (thông qua Bounding Box từ mô hình YOLO26), một vùng không gian tương ứng trên bản đồ độ sâu sẽ được trích xuất. Để loại bỏ nhiễu từ phong nền (background noise), hệ thống không sử dụng giá trị trung bình mà tính toán Bách phân vị thứ 80 (80th Percentile) của vùng không gian đó. Phương pháp này đảm bảo chỉ những điểm ảnh thuộc bề mặt lồi lên của chướng ngại vật mới được lấy làm điểm số khoảng cách cuối cùng, giúp tăng độ tin cậy của cảnh báo.


2.3 Theo dõi đa vật thể (Multi-Object Tracking) với thuật toán Centroid Tracking

2.3.1 Vai trò của bài toán theo dõi vật thể

Nhận diện vật thể (Object Detection) chỉ cung cấp thông tin không gian rời rạc tại từng khung hình riêng lẻ. Để đánh giá được mức độ nguy hiểm của một phương tiện đang di chuyển, hệ thống cần có khả năng "ghi nhớ" và liên kết các kết quả nhận diện của cùng một phương tiện đó xuyên suốt nhiều khung hình liên tiếp. Quá trình gán và duy trì định danh (ID) cố định này được gọi là Theo dõi Đa vật thể (Multi-Object Tracking - MOT).

2.3.2 Thuật toán Centroid Tracking

Trong hệ thống SmartNav, module theo dõi vật thể đóng vai trò then chốt trong việc phân tích véc-tơ chuyển động (Motion Vector) để xác định vật cản đang tiến lại gần hay ra xa người dùng. Hệ thống áp dụng thuật toán theo dõi tâm (Centroid Tracking) tối ưu cho tốc độ cao.



Hình 2.8: Minh họa thuật toán Centroid Tracking tính toán khoảng cách Euclid giữa hai khung hình liên tiếp

Quy trình hoạt động được diễn ra theo các nguyên tắc hình học cơ bản:

1. **Tính toán tâm hình học (Centroid):** Từ tọa độ khung bao do YOLO26 cung cấp, hệ thống xác định điểm tâm của vật thể trên không gian 2D.
2. **Đo lường khoảng cách Euclid:** Khi nhận được dữ liệu khung hình mới, hệ thống tính toán khoảng cách Euclid giữa tâm của vật thể ở khung hình hiện tại và tâm của các vật thể đã được định danh ở khung hình trước đó. Khoảng cách Euclid (d) giữa điểm $A(x_1, y_1)$ ở khung hình trước và điểm $B(x_2, y_2)$ ở khung hình hiện tại được tính bằng công thức:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \quad (2.1)$$

3. **Gán định danh (ID Assignment):** Dựa trên thuật toán láng giềng gần nhất (Nearest Neighbour), nếu khoảng cách Euclid nhỏ hơn một ngưỡng cho phép (tương đương với việc vật thể chỉ di chuyển một đoạn ngắn giữa hai khung hình liên tiếp), hệ thống sẽ gán ID cũ cho vật thể mới. Ngược lại, nếu khoảng cách vượt ngưỡng, một vật thể hoàn toàn mới sẽ được cấp ID mới.

4. **Duy trì vòng đời (Object Lifecycle):** Để xử lý tình huống vật cản bị che khuất tạm thời (Occlusion) rồi xuất hiện lại, hệ thống sử dụng một bộ đếm số khung hình vắng mặt. Một ID chỉ bị xóa khỏi bộ nhớ theo dõi nếu nó không xuất hiện lại sau một khoảng thời gian nhất định (ví dụ: `max_disappeared = 30` khung hình).

Sự kết hợp đồng bộ giữa mô hình nhận diện YOLO26, mô hình độ sâu MiDaS và thuật toán theo dõi tạo ra một tập dữ liệu không gian - thời gian hoàn chỉnh, làm tiền đề vững chắc cho việc thiết kế Khối Đánh giá Nguy hiểm (Danger Analyzer) ở chương tiếp theo.

Chương 3 XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG SMARTNAV

3.1 Thu thập và Xử lý Tập dữ liệu (Dataset Preparation)

3.1.1 Nguồn dữ liệu huấn luyện

Sự thành công của bất kỳ mô hình học sâu nào đều phụ thuộc rất lớn vào chất lượng của tập dữ liệu huấn luyện. Để phục vụ bài toán nhận diện vật cản giao thông và hỗ trợ người khiếm thị, hệ thống sử dụng tập dữ liệu WOTR (World on the Road). Tập dữ liệu này bao gồm hàng ngàn hình ảnh đa dạng về các bối cảnh giao thông thực tế như đường phố đô thị, vỉa hè, các loại phương tiện và chướng ngại vật phổ biến. Các nhãn trong tập dữ liệu gốc đã được hệ thống ánh xạ (map) sang tiếng Việt theo chuẩn cấu hình của bộ nhận diện nhằm phục vụ module Text-to-Speech (ví dụ: `person` → người, `car` → ô tô, `pothole` → ổ gà).



Hình 3.1: Một số hình ảnh minh họa và Bounding Box đã được gán nhãn từ tập dữ liệu WOTR

3.1.2 Tiền xử lý và tăng cường dữ liệu (Data Augmentation)

Để đảm bảo mô hình YOLO26 hoạt động tối ưu trên các kích thước đầu vào khác nhau từ thiết bị di động, dữ liệu được tiền xử lý bằng kỹ thuật Letterboxing. Kỹ thuật này sử dụng hàm `resize_keep_aspect` kết hợp với `pad_to_square` nhằm thay đổi kích thước ảnh về chuẩn 640×640 pixel mà không làm thay đổi tỷ lệ khung hình (Aspect Ratio), giúp bảo toàn các đặc trưng hình học cốt lõi của vật thể cần đường.


3.2 Kiến trúc tổng thể của hệ thống SmartNav

3.2.1 Phân tích yêu cầu hệ thống

Hệ thống được thiết kế hướng tới khả năng xử lý thời gian thực (Real-time). Đối với người khiếm thị, một độ trễ nhỏ trong việc phát ra cảnh báo có thể dẫn đến nguy cơ va chạm vật lý. Do đó, yêu cầu đặt ra là hệ thống phải duy trì tốc độ khung hình (FPS) ổn định, phân tách rõ ràng luồng xử lý giao diện hiển thị và luồng tính toán các mô hình trí tuệ nhân tạo nặng.

3.2.2 Sơ đồ khối hệ thống

Để giải quyết bài toán trên, SmartNav áp dụng kiến trúc Client-Server (Khách - Chủ) chia thành hai khối độc lập hoạt động song song.



Hình 3.2: Sơ đồ kiến trúc tổng thể và luồng truyền tải dữ liệu hệ thống SmartNav

Client (ứng dụng Web xây dựng bằng React) chịu trách nhiệm thu thập luồng video liên tục từ Camera, nén và đẩy qua mạng. Server (xây dựng bằng FastAPI) đóng vai trò trung tâm phân tích, tiếp nhận khung hình và chia luồng chạy song song hai mô hình YOLO26 và MiDaS. Dữ liệu sau đó được tổng hợp tại Danger Analyzer trước khi trả về Client.

3.3 Xây dựng Khôi Trí tuệ Nhân tạo (AI Pipeline)

3.3.1 Nhận diện vật cản với YOLO26

Việc tích hợp YOLO26 loại bỏ hoàn toàn quá trình NMS (Non-Maximum Suppression) và thuật toán DFL (Distribution Focal Loss) như đã phân tích ở Chương 2, giúp quá trình suy luận (Inference) giảm thiểu chi phí tính toán CPU. Mô hình trực tiếp xuất ra tọa độ khung bao và điểm tin cậy (Confidence Score).

3.3.2 Ước lượng chiều sâu và Kỹ thuật Fallback

Với mô hình MiDaS, sau khi dự đoán được bản đồ thị sai (Disparity Map), thuật toán sẽ sử dụng mặt nạ Bounding Box do YOLO26 cung cấp để trích xuất không gian độ sâu của từng vật thể. Thay vì tính trung bình toàn vùng (dễ bị nhiễu do nền phía sau), hệ thống áp dụng kỹ thuật Bách phân vị thứ 80 (80th Percentile) để cô lập bề mặt lỗi lên gần camera nhất:

Listing 3.1: Kỹ thuật lọc nhiễu chiều sâu bằng bách phân vị

```
1 region = depth_map[y1:y2, x1:x2]
2 # Trích xuất bách phân vị thứ 80 i   d i n   c h o   b   m   t
   c h   n g   n g i   v   t
3 score = float(np.percentile(region, 80))
```

Bên cạnh MiDaS, hệ thống cung cấp phương pháp dự phòng (Depth Fallback) dựa trên Tỷ lệ diện tích khung bao so với toàn khung hình nhằm đảm bảo tính chịu lỗi (Fault tolerance) khi tài nguyên phần cứng bị giới hạn.

3.3.3 Theo dõi quỹ đạo (Centroid Tracking)

Để dự đoán hướng di chuyển của phương tiện, thuật toán Tracking tính toán sự thay đổi tọa độ tâm hình học xuyên suốt tối đa 6 khung hình gần nhất. Bằng cách lấy trung bình sự dịch chuyển trên trục tung (Δy) và trục hoành (Δx), hệ thống xác định được vật cản đang tiến lại gần (Approaching) hay ra xa (Receding):

Listing 3.2: Phân tích véc-tơ chuyển động xác định hướng

```
1 avg_dy = np.mean([d[1] for d in deltas])
2 avg_dx = np.mean([d[0] for d in deltas])
3 # V t t h t i i n l i g n camera s í l m k c h t h c Bbox t n g , t r c
  Y thay i
4 if avg_dy > 3:
5     direction = "approaching"
6 elif avg_dy < -3:
7     direction = "receding"
```

3.4 Khôi Đánh giá Nguy hiểm (Danger Fusion Engine)

3.4.1 Ma trận trọng số và Thuật toán Danger Score

Module Fusion Engine tổng hợp dữ liệu từ YOLO, MiDaS và ByteTrack để lượng hóa mức độ rủi ro thành Điểm số Nguy hiểm (Danger Score). Thuật toán áp dụng hệ số tổng có trọng số:

$$Score = (W_{obj} \times 0.4) + (W_{dist} \times 0.3) + (W_{speed} \times 0.2) + (W_{dir} \times 0.1) \quad (3.1)$$

Trong đó, các tham số tính được định nghĩa nghiêm ngặt: W_{obj} (Xe tải = 1.0; Ô gà = 0.70; Biển báo = 0.25); Khoảng cách rất gần = 1.0; Di chuyển cực nhanh = 1.0; Đang tiến trực diện = 1.0. Kết quả đầu ra được phân nhóm làm 4 cấp độ cảnh báo: **LOW** (An toàn), **MEDIUM** (Chú ý), **HIGH** (Nguy hiểm) và **CRITICAL** (Khẩn cấp).

Cấp độ	Ngưỡng Điểm	Kịch bản Xử lý
LOW	< 0.30	Hiển thị viền xanh, không phát cảnh báo
MEDIUM	$0.30 - 0.54$	Phát tần số âm thanh thấp, cảnh báo có chướng ngại vật
HIGH	$0.55 - 0.77$	Phát cảnh báo đỏ, đọc rõ tên và hướng đi của xe cộ
CRITICAL	≥ 0.78	Báo động khẩn cấp tần số cao, yêu cầu người dùng dừng lại

Bảng 3.1: Bảng phân loại ngưỡng điểm nguy hiểm và kịch bản cảnh báo

3.5 Xây dựng Giao tiếp mạng và Giao diện Người dùng

3.5.1 Luồng truyền tải WebSocket

Nhằm tối ưu hóa băng thông, Client không truyền tải video định dạng thô. Luồng Camera (<video>) được trích xuất và vẽ lên <canvas>. Tại đây, thuật toán sử dụng hàm `requestAnimationFrame` để giới hạn việc lấy mẫu ở mức 5 FPS, sau đó nén khung hình dưới dạng Blob JPEG (quality = 0.7) trước khi đẩy vào đường ống WebSocket:

Listing 3.3: Ép khung hình và nén JPEG tại Client

```

1 canvasEl.toBlob((blob) => {
2   if (blob && wsRef.current?.readyState === WebSocket.OPEN) {
3     blob.arrayBuffer().then((buf) => wsRef.current.send(buf))
4   }
5 }, 'image/jpeg', 0.7)

```

3.5.2 Hệ thống cảnh báo đa kênh: HUD và Web Audio API

Giao diện trực quan áp dụng phong cách hiển thị HUD (Heads-Up Display) hiện đại. Tọa độ của các chướng ngại vật được đánh dấu bằng góc viền (Corner Box) và bảng dữ liệu RadarPanel, đổi màu cảnh báo từ Xanh sang Đỏ tùy theo mức độ Danger Score.



Hình 3.3: Giao diện hiển thị trực quan HUD thời gian thực của Smart-Nav

Cuối cùng, bên cạnh việc sử dụng Text-to-Speech (gTTS) để đọc rõ tên vật cản bằng tiếng Việt, hệ thống áp dụng **Web Audio API** để kích hoạt tín hiệu báo động độc lập.


Bằng cách khai báo bộ tạo sóng `AudioContext`, hệ thống sinh ra các tần số thay đổi linh hoạt (từ tiếng bíp 440Hz ở mức LOW đến chuỗi báo động giạt cục 1000Hz ở mức CRITICAL), tạo phản xạ có điều kiện ngay lập tức cho người khiếm thị trước khi câu nói TTS kịp xử lý xong.

Chi tiết mã nguồn của Backend và Frontend được liệt kê đầy đủ tại Phụ lục B.

Chương 4 KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 Đánh giá quá trình huấn luyện mô hình YOLO26

Để đánh giá chất lượng của khối nhận diện vật cản, hệ thống trích xuất các biểu đồ đánh giá trong quá trình huấn luyện (Training) trên tập dữ liệu WOTR. Các chỉ số quan trọng nhất bao gồm hàm mất mát (Loss) và độ chính xác trung bình (mAP - mean Average Precision).



Hình 4.1: Biểu đồ theo dõi hàm mất mát và độ chính xác mAP trong quá trình huấn luyện YOLO26

Dựa vào biểu đồ Hình ??, có thể thấy mô hình hội tụ khá nhanh và ổn định nhờ bộ tối ưu hóa MuSGD. Chỉ số mAP@50 đạt mức [...] %, và mAP@50-95 đạt [...] %. Các thông số này chứng minh mô hình có khả năng nhận diện xuất sắc, tỷ lệ dương tính giả (False Positive) rất thấp, đặc biệt nhạy bén với các vật thể nhỏ ở khoảng cách xa như biển báo hoặc ổ gà.

4.2 Đánh giá Hiệu năng và Độ trễ (Real-time Performance)

Đối với hệ thống hỗ trợ người khiếm thị, độ trễ thời gian thực là yếu tố sống còn. Quá trình thực nghiệm được tiến hành trên môi trường máy chủ [GHI TÊN CẤU HÌNH CPU/GPU VÀO ĐÂY, VD: Intel Core i7, RAM 16GB].


Nhờ áp dụng cơ chế ép khung hình (Frame Skip) tại Client và truyền tải qua Web-Socket, hệ thống đạt được hiệu năng cực kỳ ấn tượng. Theo log hệ thống và thông số hiển thị trực tiếp trên giao diện HUD, thời gian xử lý toàn trình (từ lúc nhận khung hình, chạy YOLO26, chạy MiDaS đến lúc tính toán xong Danger Score) chỉ dao động ở mức **34ms/frame**. Tốc độ này tương đương với khả năng xử lý xấp xỉ ≈ 29 FPS (Frames Per Second). Kết hợp với thuật toán nội suy quỹ đạo ByteTrack, luồng video hiển thị trên giao diện người dùng hoàn toàn mượt mà, không xảy ra hiện tượng giật lag hay thất nút cổ chai băng thông.

4.3 Thực nghiệm các Kịch bản Cảnh báo Nguy hiểm

Hệ thống được thử nghiệm với các video đường phố thực tế để đánh giá sự nhạy bén của Khối Danger Analyzer và giao diện cảnh báo. Dưới đây là 3 kịch bản cốt lõi đã được ghi nhận:

4.3.1 Kịch bản 1: Môi trường An toàn (LOW)


Trong điều kiện đường sá thông thoáng hoặc các phương tiện ở khoảng cách rất xa, hệ thống đánh giá Danger Score ở mức dưới 30%. Giao diện HUD và các Corner Box giữ màu Xanh lá (Mã màu: #00ff87). Ở trạng thái này, Web Audio API chỉ phát ra âm thanh bíp tần số thấp (440Hz) gián cách để báo hiệu hệ thống vẫn đang hoạt động, không làm phiền người dùng.



Hình 4.2: Giao diện hiển thị trạng thái An Toàn (Mức LOW)

4.3.2 Kịch bản 2: Cảnh báo Chú ý (MEDIUM/HIGH)


Khi có phương tiện xuất hiện trong vùng quan tâm (Center Zone) hoặc di chuyển lại gần, Danger Score lập tức tăng lên biên độ 55% - 77%. Giao diện tự động chuyển màu Vàng/Cam. Lúc này, hệ thống TTS tiếng Việt được kích hoạt để đọc tên vật thể và khoảng cách (Ví dụ: "Chú ý, phát hiện xe máy ở khoảng cách trung bình").



Hình 4.3: Giao diện hiển thị trạng thái Chú ý (Mức HIGH)

4.3.3 Kịch bản 3: Báo động Khẩn cấp (CRITICAL)

Hình ?? minh họa một tình huống thực tế khi một chiếc ô tô tiến sát vào vị trí người dùng. Mô hình MiDaS định lượng chiều sâu và phát hiện vật thể đã vượt ngưỡng an toàn, kết hợp với ByteTrack phân tích véc-tơ chuyển động (Approaching). Danger Score ngay lập tức chạm mốc **88%**. Hệ thống chuyển toàn bộ giao diện sang màu Đỏ (#ff1744), đồng thời Web Audio API kích hoạt chuỗi âm thanh giật cục tần số 1000Hz, chèn thêm câu lệnh TTS: "Khẩn cấp! Ô tô tiến nhanh phía trước!" để tạo phản xạ dừng lại ngay lập tức cho người khiếm thị.



Hình 4.4: Giao diện báo động Đỏ khi vật cản tiến sát (Mức CRITICAL - Danger Score 88%)

4.4 Đánh giá tính Ổn định của Hệ thống (Session Stats)

Dựa trên dữ liệu JSON trích xuất từ lịch sử phân tích (History) sau một phiên chạy thử nghiệm, hệ thống đã quét thành công liên tục [ĐIỀN TỔNG SỐ SCANS TỪ JSON] khung hình mà không gặp sự cố crash ứng dụng. Trong đó:

- Số lần cảnh báo An toàn (LOW): [ĐIỀN SỐ] lần.
- Số lần cảnh báo Chú ý (MEDIUM/HIGH): [ĐIỀN SỐ] lần.

- Số lần báo động Khẩn cấp (CRITICAL): [ĐIỀN SỐ] lần.

Sự phân bổ này cho thấy hệ thống lọc nhiễu tốt, không đưa ra các cảnh báo khẩn cấp giả mạo (False Alarm) một cách bừa bãi, đảm bảo cung cấp thông tin tinh gọn và chính xác nhất cho người dùng khiếm thị trong suốt hành trình di chuyển.

Phụ lục A Các câu hỏi thường gặp

Phụ lục B Liệt kê source code